Reinforcement Learning in Pacman aan de hand van Proximal Policy Optimization

Elias Nijs, Bavo Verstraeten

Artificiele Intelligentie
Vakgroep Toegepaste Wiskunde, Informatica en Statistiek
Universiteit Gent

22 December 2022

Reinforcement Learning in Pacman aan de hand van Proximal Policy Optimization

Elias Nijs, Bavo Verstraeten

Artificiele Intelligentie
Vakgroep Toegepaste Wiskunde, Informatica en Statistiek
Universiteit Gent

1. Introductie

Pac-Man is een welbekend spel. Het is een spel met simpele regels, maar vergt toch enig strategisch inzicht. Dit is waarom Pac-Man volgens ons het perfecte spel is om te automatiseren.

1.1. Pacman

Eerst en vooral zullen we even de werking van het spel toelichten.

De speler bestuurt een wezen genaamd Pac-Man. De speler kan rondlopen in een groot doolhof. Hierin liggen er pellets op paden, en lopen ook spoken rond. De speler heeft als doel de spoken te ontwijken en alle pellets te verzamelen. Daarbovenop zijn er ook nog speciale pellets: de power pellets. Als Pac-Man zo een pellet verzamelt, gaat hij enkele seconden in een powerup state. Indien hij in deze state een spook aanraakt, sterft hij niet, maar verdwijnt deze geest enkele seconden van de map.

1.2. Agents

Het spel kent verschillende entiteiten die keuzes moeten maken. Pac-Man moet de paden afgaan die zijn score maximaliseeert en zijn kans op sterven minimaliseert.

Daarnaast moeten ook dee spoken keuzes maken. Zo zullen ze idealiter afslagen nemen die de kans om Pac-Man te verslaan vergroten.

Het leek ons interessant deze entiteiten tegelijk te trainen. Aangezien dit een spel is en er geen trainingsdata op voorhand beschikbaar is, zullen we gebruik maken van Reinforcement Learning. Op deze manier zouden beide entiteiten tegelijk proberen leren de andere entiteit te verslaan.

1.3. Onderzoeksvraag

Hieruit volgen onze oorspronkelijke onderzoeksvragen:

- Wint Pac-Man of winnen de geesten?
- Welke strategieen ontdekken zowel de Pac-Man agent als de geest agents?
- Welke invloed hebben het aantal geesten en de map lay-out op de vorige onderzoeksvragen?

Echter, na verloop van dit onderzoek, bleek al snel dat het onderzoeken van deze vragen heel wat tijd in beslag zou nemen. Diep in ons onderzoek zijn we dan tot de conclusie gekomen dat we deze tijd niet hadden. Dit heeft ons gedwongen onze onderzoeksvragen te herschalen.

We hebben beredeneerd dat het wel mogelijk is deze onderzoeksvragen te onderzoeken als we ons enkel focussen op het trainen van Pac-Man. Het trainen van de spoken is de factor die de schaal van dit project te groot maakt voor de tijd die we hadden.

Het nieuwe plan is dus om enkel de Pac-Man een eigen agent te geven met nog steeds als doel zoveel mogelijk pellets te eten en spoken te ontwijken, en de spoken willekeurig te laten rondbewegen. Dit zorgt voor gelijkaardige, maar andere, onderzoeksvragen:

- Kan Pac-Man winnen?
- Welke strategieen ontdekt Pac-Man?
- Welke invloed hebben het aantal spoken en de map lay-out op de vorige onderzoeksvragen?

1.4. Oplossingsmethoden

Er bestaan verschillende Reinforcement Learning Algoritmes, zoals DQN, TRPO.

Na verschillende bronnen te raadplegen, zijn we

tot de conclusie gekomen dat PPO het stabielste en best presterende is van deze algoritmes. We zullen dan ook dit algoritme gebruiken om onze Pac-Man agent te trainen.

Een moeilijk deel van dit onderzoek was het bepalen van de hyperparameters om aan dit algoritme mee te geven. We hebben dan ook gebruik gemaakt van een library die bepaalde algoritmes gebruikt om parameters van een functie te tunen.

Deze methoden worden uitgebreid besproken in het vervkolg van dit verslag.

2. Methodiek

We bespreken nu uitvoerig hoe we dit onderzoek hebben uitgevoerd. In grote lijnen kunnen we dit opdelen in drie grote fasen:

1. Implementatie van het spel
2. Gebruik van Proximal Policy Optimization
3. Hyperparamter optimalisatie aan de hand van Optuna

We bespreken elk van deze in detail.

2.1. Implementatie van Pac-Man

Het Pac-Man spel werd geimplementeerd in python aan de hand van de ncurses bibliotheek. De ncurses bibliotheek levert verschillende manieren om een terminal-gebassseerde user interface uit te bouwen. Er werd gekozen om het spel zelf te maken om de implementatie zo simpel en uitbreidbaar mogelijk te houden.

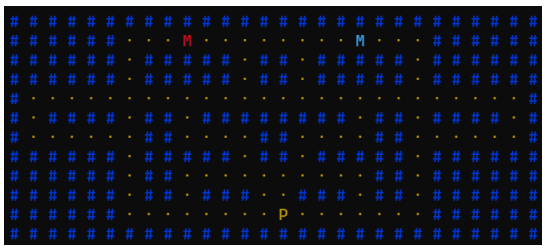

In het begin van het progrmma wordt de ncurses bibliotheek geimporteerd en wordt deze gebruikt om een nieuw venster binnen de terminal te creeeren alsook om de controller voor de gebruikers input op te zetten.

Vervolgens wordt het spel geinitialiseerd. Het spel wordt voorgesteld door een object dat een 2d array bevat. Deze array houdt de muren, pellets, ... bij. Verder houdt dit object ook Pac-Man en de spoken bij, alsook enkele statistieken over de huidige staat van het spel.

Eens het spel geinitialiseerd is, wordt de spel-lus opgestart. Deze bestaat uit enkele delen die telkens na elkaar worden opgeroepen. Deze zijn de volgende:

1. `kb_qetqueue(screen)` om alle input op te halen.
2. `handleinput(game, screen)` om de ingelezen input af te handelen.
3. `gameupdate(game)` om op basis van de huidige staat en de input een nieuwe staat te creeren.
4. `gamerender(game)` om de nieuwe staat weer te geven.
5. Tot slot enkele lijnen om de frame-rate te begrenzen zodat wat er gebeurt interpreteerbaar blijft voor de gebruiker.

Wanneer we de agent zullen trainen worden stappen een, twee, vier en vijf weggelaten. Deze zijn enkel nodig indien een mens met het spel wilt interageren. Indien we deze niet weglaten, zouden we het trainingsprocess significant en onnodig verlengen.

Tot slot werd om zowel het trainen te verbeteren als om het testen van de agent in een nieuwe omgeving mogelijk te maken, de functionaliteit om verschillende omgevingen in te laden gecreeerd. Voor het spel opstart, moet een omgeving geselecteerd worden. Tijdens de initialisatie zal het spel dan de geselecteerde omgeving inladen en parsen. Omgevingen worden gedefinieerd in een tekst bestand en doorgegeven via de locatie van dit bestand. Op deze manier wordt het zeer simpel om een nieuwe omgeving te maken en gebruiken.
Zo een omgeving ziet er als volgt uit:

```
##############
#P..........#
#.####.#####.#
#.####.#####.#
#...........#
#.#######.##.#
#..........G#
##############
```

Dit is de inhoud van het bestand `code/pac-man/maps/lv2.txt`.

We hanteren hierbij de volgende conventie.

#	*muur*
.	*pellet*
0	*powerup*
	gang
P	*start positie Pac-Man*
G	*start positie spook*

De implementatie van het spel kan teruggevonden worden in de volgende bestanden:

1. functie implementaties: `code/pacman/pacman.py`
2. datastructuren en constanten: `code/pacman/pacman_h.py`

2.2. Proximal Policy Optimization (PPO)

PPO is een een reinforcement algoritme dat aan populariteit gewonnen heeft in de laatste jaren. In dit onderzoek kijken we hoe dit algorithme zich gedraagt op een relatief simpele maar dynamisch omgeving aan de hand van het spel Pac-Man.

We bekijken eerst hoe PPO werkt en vervolgens hoe we dit algoritme gebruikt hebben.

2.2.1. Achtergrond PPO

PPO is een reinforcement learning algoritme ontwikkeld aan Open AI. Het algoritme heeft success in een breed veld aan taken, gaande van ataris spellen tot robot controllers tot een meer ingewikkeld spel zoals dota2.

Het grote probleem met reinforcement learning algoritmes is het feit dat de training data afhankelijk is van het huidige policy. Dit komt omdat de agent zijn eigen training data genereert door met de omgeving te interageren. Dit in tegenstelling tot supervised learning, waar we een statische dataset hebben om op te trainen.

Dit betekent dus dat de datadistributies over zowel de observaties als de rewards constant in flux zijn terwijl de agent aant het leren is. Terwijl we trainen ondervinden we dan ook een grote hoeveelheid onstabiliteit. Daarboven op zijn reinforcement learning algoritmes ook nog eens zeer gevoelig aan de hyperparamters en de waarden bij initalisatie, wat de stabiliteit van de algoritmes nog zal verlagen.

Het probleem met reinforcement learning algoritmes ligt er dus in om zo stabiel mogelijk te zijn, zonder computationeel te veel rekenkracht nodig te hebben en tegelijkertijd het aantal nodige samples laag te houden. Daarnaast worden dit soort algoritmes ook vaak heel complex omwille van deze problemen. Een bijkomende moeilijkheid is dus om de complexiteit van de implementatie laag te houden.

PPO probeert deze moeilijkheden aan te pakken. De achterliggenede doelen van het algoritme zijn de volgende

1. gemakkelijk implementeerbaar
2. sample efficient
3. makkelijk te tunen

PPO is een on-policy-gradient methode. Dit betekent dat het, in tegenstelling tot bijvoorbeeld DQN die leert van opgeslagen offline data, PPO online leert. In plaats van een buffer met vorige ervaringen bij the houden zal PPO dus direct leren van een ervaring. Eens een batch ervaring gebruikt is, wordt deze weggegooid. Een nadeel hiervan is wel dat dit soort methoden minder sample-efficient zijn dan q-learning methodes.

We kijken eerst naar vanilla policy gradient methods:

$$L^{PG}(\theta) = \hat{E}_t\Big[\log \pi_\theta(a_t|s_t)\hat{A}_t\Big]$$

Het grote probleem hiermee is dat als we gradient-descent op een enkele batch van ervaringen blijven toepassen, dan zullen de paramters in het netwerk heel ver buiten het bereik van waar deze data verzameld was komen te liggen. Dit zorgt er bijvoorbeeld voor dat de advantage function, die een benadering van het echte advangtage is, compleet fout wordt. We zijn op deze manier dus in principe ons policy aan het ondermijnen. Uit dit probleem komen we tot de volgende vraag:

Hoe kunnen we de stap met de grootste verbetering nemen op een policy met de data die we momenteel hebben, zonder dat we zo ver stappen dat de performantie ineenstort?

Om dit op te lossen kunnen we een beperking invoeren die beperkt hoe ver het nieuwe policy van het oude policy kan komen te liggen. Dit idee werd geintroduceerd in de paper *Trust Region Policy Optmization (TRPO)*. Deze paper vormt ook de basis voor PPO.

De objective function in TRPO is de volgende:

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$$

$$\underset{\theta}{maximize}\ \hat{E}_t\left[r_t(\theta)\hat{A}_t\right]$$

We zien een verandering van de log operatie in vanilla policy gradients naar een deling door $\pi_{\theta_{old}}$. Om ervoor te zorgen dat het nieuwe policy conservatief blijft, wordt hier nog een KL (Kullback-Leibler) beperking aan toegevoegd:

$$\hat{E}_t\left[KL[\pi_{\theta_{old}}(.|s_t), \pi_\theta(.|s_t)]\right] \leq \delta$$

Deze KL beperking leidt echter wel tot significante overhead tijdens de training. Hetgeen PPO hierop probeert te verbeteren is om deze beperking direct in ons optimalisatie-doel te verwerken.

We komen nu tot de objective functie van PPO.

$$\hat{E}_t\left[\min\left(r_t(\theta)\hat{A}_t,\ clip(r_t(\theta), 1-\varepsilon, 1+\varepsilon)\hat{A}_t\right)\right]$$

Merk op dat het probabiliteits ratio r geknipt wordt op $1-\varepsilon$ of $1+\varepsilon$ afhankelijk van het teken van $\hat{A}_t$. Dit is duidelijker te zien op de volgende afbeelding uit de originele paper:

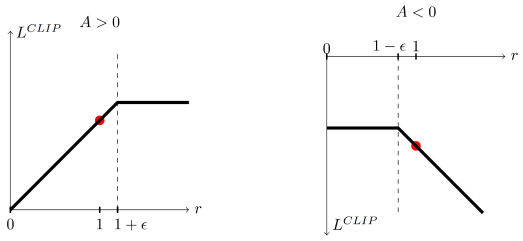

Met PPO bereiken we dus hetzelfde doel als met TRPO zonder de grote overhead die meekomt met het bereken van de KL-divergentie. verder nog, uit metingen blijkt dat PPO vaak beter presteert dan TRPO.

We bekomen het volgende algoritme:

```
for i ← 1,2,... do
  for actor ← 1,2,...,N do
    run policy π_θold for T steps
    compute Â_1,...,Â_T
  done
  optimize surrogate L wrt θ,
    with K epochs
    and minibatch size M ≤ NT
  θ_old ← θ
done
```

Nu we PPO in detail bekeken hebben, kunnen we overgaan naar hoe we dit algoritme gebruikt hebben.

2.2.2. Gebruik PPO

2.2.2.1. Stable Baselines 3

Het is natuurlijk niet de bedoeling dat we zelf deze ingewikkelde algoritmes implementeren. We gaan daarom gebruik maken van een library die voor ons deze algoritmes ter beschikking stelt. Het zelf implementeren zou te veel tijd kosten, en zou waarschijnlijk slechter presteren dan de implementaties van een library.

Na verschillende bronnen te raadplegen, hebben we besloten gebruik te maken van de library Stable Baselines 3. Deze library biedt ons een heel eenvoudige manier van modellen configureren en trainen. Een algoritme genaamd 'ALGO', trainen met hyperparameters

ALGO(Policy, Env, HYPER).learn(STEPS)

op te roepen. De enige parameters die we nog niet in dit verslag besproken hebben, zijn Policy en Env.

De Policy bepaalt hoe ons neuraal netwerk zelf er uit ziet, en hoe zijn nodes gestructureerd zijn. Wij hebben gekozen voor een Multilayer Perceptron Policy, wat de nodes opsplitst in verschillende hidden layers. Wij hebben het zo ingesteld dat er 2 hidden layers zijn, elk met 64 nodes.

De Env is ofwel een OpenAi Gym Environment, ofwel een SubprocVecEnv. Dit laatste is een wrapper rond een Gym Environment, maar staat Stable Baselines 3 toe om ons PPO algoritme over verschillende threads uit te voeren. Hierbij worden verschillende stappen over verschillende threads uitgevoerd, en versnelt dus het trainingsproces.

2.2.2.2. OpenAI Gym Environments

Een OpenAi Gym Environment is een interface die door verschillende Reinforcement Learning Libraries gebruikt wordt om de omgeving (voor ons het spel) voor te stellen waarop we willen een agent trainen.

Om aan deze interface te voldoen, moeten we 3 functies implementeren.

1. `init()`
2. `reset()`
3. `step()`

We bekijken elk van deze in detail.

2.2.2.2.1. Initialisatie

De init wordt door de library opgeroepen in het begin van de training. Deze heeft als doel om de environment en zijn variabelen te initialiseren, maar nog belangrijker om de action space en de observation space in te stellen.

De action space definieert de mogelijke acties die de agent kan uitvoeren. In ons geval is hier geen ambiguiteit aan: De 4 mogelijke acties van Pac-Man zijn een stap zetten in elk van de 4 windrichtingen.

De observation space definieert hoe een observation eruit ziet. Een observation is de verzameling van variabelen waarnaar de agent moet kijken om een actie aan te raden. Deze space is echter veel moeilijker optimaal te definieren dan de action space. We hebben deze space dan ook grondig beexperimenteerd en onderzocht.

We zijn begonnen met letterlijk alle variabelen in deze space te steken. Dit omvatte dus: elke tile van de map, de positie van Pac-Man, de positie en richting van de geesten, hoe lang een geest nog verwijderd is van de map nadat deze verslagen was, hoe lang we nog in de power state zitten, wat onze score is, wat onze combo is (zorgt voor hogere score als we verschillende geesten snel na elkaar verslaan) en hoeveel pellets er nog over zijn. Dit leek ons het totaalplaatje, waar het model dus het meeste linken kan ontdekken. Het bleek echter al snel dat dit te veel parameters waren. Door waarschijnlijk een te veel aan overbodige variabelen, trainde de agent trager dan verwacht, en presteerde hij ook slechter dan verwacht.

Als volgende stap hebben we het andere uiterste onderzocht. We hebben zo weinig mogelijk variabelen meegegeven, enkel degene waarvan we zelf dachten dat ze belangrijk waren in het maken van een keuze. Op deze manier zou volgens ons de agent heel snel duidelijke linken kunnen leggen. Deze variabelen waren dan: de positie van Pac-Man, de positie van de geesten (dus niet meer de richting), hoe lang we nog in de power state sitten, en elke tegel van de map die geen muur is. Het meegeven van muren leek ons overbodig, aangezien binnen dezelfde training deze constant zijn en dus de keuze niet beinvloeden. Al snel bleek dat onze agent niet alleen sneller leerde, ook het eindresultaat was beduidend beter. Het bleek dat deze variabelen dus een betere keuze waren.

Echter, na verder trainen en onderzoeken, bleek dat het weglaten van bepaalde variabelen voor problemen kon zorgen. Zo zou de agent waarschijnlijk te veel vanbuiten leren en zich niet snel aanpassen, en dus door slecht geluk toch kunnen slecht presteren. Aangezien het vanbuiten leren van een map niet de bedoeling is van een agent, en omdat we liever toch nog een iets stabieler resultaat verlangen, hebben we nog een laatste onderzoek gedaan naar deze observation space. We zijn uiteindelijk uitgekomen op een mooie middenweg tussen onze vorige observation spaces. Zo hebben we besloten de muren terug op te slaan, voor moesten we ooit onze code uitbreiden om op verschillende mappen tegelijk te trainen. Ook hebben we de richting van ghosts terug opgeslagen. Onze finale observation space bestaat nu uit: elke tile van de map, de positie van Pac-Man, de positie en richting van de geesten en hoe lang we nog in de power state zitten. Deze space produceert gemiddeld iets lagere scores dan de vorige space, maar is een stuk consistenter. Zo zijn er veel minder runs waarbij Pac-Man sterft binnen enkele stappen. Ook is er nu de mogelijkheid het onderzoek uit te breiden om te trainen op meerdere mappen.

2.2.2.2.2. Reset

Deze functie wordt door de libraries opgeroepen wanneer een run geeindigd is en een nieuwe run moet opgestart worden. Het enigste dat hier moet gebeuren is dat de environment opnieuw opgestart wordt en dat alle variabelen terug naar hun beginpositie gezet worden. Hier gebeurt niets waar er onderzoek naar nodig was.

2.2.2.2.3. Step

Deze functie is mogelijks de belangrijkste functie in een Gym environment. Hij stelt een stap in het trainingsprocess voor. De library roept deze functie elke stap van zijn training op, met als argument een actie die binnen de action space ligt. De functie moet dan deze actie uitvoeren en dus de state aanpassen, en geeft dan de nieuwe observatie (gespecificeerd door de observation space) en de reward terug, en of het spel gedaan is of niet (bij ons is dit of Pac-Man verslagen is of alle pellets verzameld zijn). De reward beschrijft hoe voordelig de genomen actie was. De agent gebruikt dan deze reward om zijn neuraal netwerk te updaten, aan de hand van het gekozen algoritme (bij ons PPO).

Deze reward is, net zoals de observation space, een belangrijke factor in het presteren van de agent. Het is dan ook vanzelfsprekend dat dit een kern van ons onderzoek was.

We zijn begonnen met een zeer simpele, straight forward, reward functie: het verschil tussen de nieuwe score en de vorige score. De reden dat we met een simpele functie begonnen zijn, is om te onderzoeken of de agent kan leren uit enkel de basis. Dit bleek al snel niet het geval. De agent stierf heel snel en was weinig geinteresseerd in de pellets. Het voelde alsof de agent willekeurige keuzes maakte. We moesten dus duidelijk de reward functie verduidelijken als hulp voor de agent.

Het eerste probleem dat we wouden oplossen, was het snel sterven. De agent zag mogelijks sterven niet noodzakelijk als iets negatiefs. Om dit te voorkomen, was het genoeg om een grote penalty te geven bij het verlies van een spel. Na deze toevoeging, zagen we de agent al snel zetten nemen die hem weg van geesten brachte. Het oppakken van pellets bleef echter willekeurig aanvoelen. Als hij een rij pellets afging, zou hij het pad pellets blijven volgen. Als er echter geen pellets in de directe omgeving waren, was de agent meer bezig met het ontwijken van de geesten dan het halen van de verdere pellets, waardoor er geen vooruitgang meer te zien was. De oplossing hiervoor is gelijkaardig aan hoe we het vorige probleem hebben opgelost: We geven een grote bonus als de agent erin slaagt om alle pellets op te pakken, en dus te winnen. Op deze manier zal de agent de pellets verzamelen even belangrijk vinden als het overleven.

De agent had hieraan genoeg om de regels van het spel te begrijpen en te volgen. Echter, er was nog geen strategisch inzicht opmerkbaar. De agent deed weinig domme dingen, maar deed ook weinig intelligente dingen. Er was dus nog een laatste aanpassing aan de reward functie nodig. We ondervonden al snel het probleem in onze reward: indien er niets gebeurde in een stap, was de reward 0, waaruit de agent niet veel info kan halen. Dit was zeker een probleem, aangezien in grotere mappen deze situatie uiterst veel gaat voorkomen. We moesten dus een bepaalde reward teruggeven in het geval er geen nieuwe pellets opgepakt werden en de agent niet gestorven is. Wat we moesten teruggeven, was echter een van de moeilijkste dilemma's van dit project. We konden namelijk ofwel een positieve reward teruggeven, of een negatieve reward. Deze twee mogelijkheden zijn dan wel tegenovergestelden, ze hebben beiden goede argumenten om gekozen te worden. We hebben dan ook beiden grondig onderzocht.

Onze eerste gedachtengang was dat, ook al was er geen strategisch denken door de agent, de agent uiteindelijk elke map kon winnen als hij gespecialiseerd raakte in het ontwijken van geesten. Uiteindelijk, na lang genoeg overleven, zal de agent wel alle pellets opgepakt hebben. Met deze argumenten in ons achterhoofd, hebben we dan de agent een positieve reward gegeven indien er niets gebeurd is (de reward voor het pakken van een pellet was natuurlijk hoger dan deze reward). Wat we verwachtten te gebeuren gebeurde echter niet. Tot onze verbazing ging de agent gewoon stilstaan in een hoek, bij elke run dezelfde. Als er een geest in de buurt kwam, zou hij even de hoek verlaten, en achteraf terug daar gaan stilstaan. Door deze manier van geesten ontwijken, bereikte hij echter nooit de andere kant van de map, en zou het spel dus nooit eindigen. Na verder onderzoek bleek dat de agent de hoek berekende die de laagste kans heeft om bezocht te worden door een geest. We konden dus tot de conclusie komen dat, statistisch gezien, bij het verlaten van die hoek het gemiddelde scoreverlies, door het stijgen van de kans op sterven door de geesten, groter was dan de scorewinst die de pellets ons brachten. Na experimenteren met hoe groot elke reward is, was er weinig verbetering te merken.

Na het vorige gefaalde experiment, was het tijd om de andere mogelijkheid te onderzoeken: een negatieve reward indien er geen verschil is in

score. Net zoals de positieve reward, heeft deze mogelijkheid overtuigende argumenten. Toen ons reward nog 0 was, zagen we weinig strategisch inzicht. Indien we echter de agent een negatieve reward geven, wordt deze geforceerd om na te denken over hoe zo snel en veilig mogelijk alle pellets te verzamelen. We verplichten de agent zeg maar om actie te ondernemen, en niet doelloos rond te dwalen. Deze strategie bleek al snel uiterst goed te werken. Bij grotere maps werd al na redelijk korte trainingen grote delen van de map opgepakt voor de agent stierf. Meer nog, hij vond manieren om pellets te pakken en ontweek tegelijkertijd de geesten. Dit was het strategisch inzicht dat we verwachtten van de agent. Dit brengt ons dan tot onze finale reward functie:

```
prev_score <- game.score
update_game()
reward <- game.score - prev_score
if game.pellets is 0:
    reward <- grote bonus
else if game.is_over:
    reward <- grote penalty
if reward is 0:
    reward <- kleine penalty
return reward
```

2.3. Optuna

Eens we PPO opgezet hadden, hadden we echter nog een probleem. Het is heel moeilijk om de hyperparameters te tunen. We zijn hiervoor op zoek gegaan naar een oplossing en kwamen op het idee om hier een framework voor te gebruiken dat dit automatisch zal doen. Optuna is zo een framework.

We bekijken hoe Optuna in elkaar zit en hoe we het gebruikt hebben.

2.3.1. Achtergrond Optuna

Traditioneel werd automatische hyperparameter optimalisatie gedaan aan de hand van oftwel grid search oftwel random search algoritmes. Grid search is een brute force algoritme dat alle mogelijke combinaties in een grid afgaat en random search zal random samplen en het beste resultaat teruggeven. Deze twee methoden zijn beide heel resource-intensive. In de laatste jaren zijn er echter verschillende soorten algoritmen ontwikkeld om dit op een betere manier te doen.

Optuna is een bibliotheek die verschillende van deze sampling algoritmen implementeert. Daarboven op biedt optuna ook nog een extra mechanisme om oplossings ruimten vroegtijdig te stoppen aan de hand van een op vooraf bepaald criterium. Dit mechanisme noemt men pruning. De combinatie van deze 2 technieken maakt het mogelijk om heel efficient de beste parameters te gaan vinden.

Voor het sampelen gebruikt optuna standaard een Bayesian optimization algorithm, gebruik makend van een Tree-structured Parzen Estimator (TPE). Dit is ook het algoritme waar wij voor kozen. Optuna heeft verder ook nog implementaties van andere sampling strategieen zoals een *NSGAII Sampler*, *CMA-ES Sampler*, *MOTPE Sampler*,...

De TPE wordt gebruikt voor een sequentieel model-gebasserde optimalisatie (SMBO) methode. Dit betekent dat sequentieel modellen gemaakt worden die de performantie van de hyperparatemers benaderen op basis van historische metingen en vervolgens nieuwe parameters gekozen worden op basis van deze modellen.

De TPE benaderd modellen $P(x|y)$ en $P(y)$. Hierbij representeert x de hyperparamters en y de geassocieerde kwaliteits score. $P(x|y)$ wordt gemodelleerd door hyperparameters te transformeren, door de verdelingen van de vorige configuratie te vervangen door niet-parametrische dichtheid.

Meer informatie hieromtrent zullen we niet geven. Voor meer informatie kan u de references bekijken.

2.4. Gebruik van Optuna

Het gebruik van optuna bestaat uit 2 delen. Het eerste deel is een Optuna studie en het tweede deel is de object functie die we aan de study meegeven.

De studie aanmaken doen we als volgt:

```
study = optuna.create_study(
  direction = "maximize")
```

Hierna roepen we de optimize functie op van de studie. Deze vraagt de objective function.

```
study.optimize(
  objective_function,
  n_trials=TUNING_STEPS,
  gc_after_trial=True)
```

Hierbij is `objective_function` de objective

functie die we meegeven, `TUNING_STEPS` het aantal keer dat we de hyperparameters updaten en tot slot `gc_after_trial=True` zet garbage collection aan zodat we niet zonder geheugen komen te zitten. Dit laatste zal het process een beetje vertragen maar vermits we anders zonder geheugen komen te zitten, hebben we geen andere keuze dan dit aan te zetten.

Nu we de optuna studie bekeken hebben, bekijken we ook de objective functie. De objective functie zal voor elke update van de hyperparamters opgeroepen worden. De objective functie bevat drie belangrijke delen. Ten eerste krijgt deze een trial argument mee van de optuna studie. Vervolgens moeten we de hyperparamters die optuna moet optimaliseren selecteren. Tot slot moeten we de metric die optuna moet maximaliseren bepalen en teruggeven.

Hyperparameters selecteren doen we als volgt. We kijken bijvoorbeeld naar het selecteren van de learning rate.

```
lr = trial.suggest_float(
  'learning_rate',
  lowerbound,
  upperbound)
```

Hier zien we dat we een float selecteren, de naam 'learning_rate' aan de parameter geven en een lower en upper bound selecteren voor de hyperparameter.

Tot slot moeten we ook nog een metric teruggeven die we willen optimaliseren. Hiervoor werd er gekozen om de gemiddelde reward terug te geven van 10 episodes van het nieuwe policy. We doen dit aan de hand van de `evaluate_policy(model, env)` functie die stable baselines ons levert.

We bekomen dan de volgende functie:

```
OBJECTIVE_PPO_PACMAN
in:  trial
1. select hyperparamters
2. env ← new pacman environment
3. model ← PPO(hyperparameters...)
4. model.learn(...)
5. mean_reward <- evaluate_policy(
     model, env)
6. return mean_reward
```

2.5. Globaal Overzicht Trainings Process

Nu elk deel van onze code en ons onderzoek overlopen is, is het tijd om te bespreken hoe onze agent effectief getraind wordt.

We beginnen met het bepalen van enkele configuratie parameters. Zo beslissen we voor elke training hoeveel stappen Optuna moet uitvoeren, hoe lang er getraind moet worden per stap die Optuna uitvoert, en hoe lang onze echte training zal duren. Deze parameters bepalen de stabiliteit, de totale uitvoeringstijd en de effectiviteit van het trainen.

Daarnaast bepalen we ook de lower- en upper bounds van elke hyperparameter die we willen tunen. Aangezien vele hyperparameters slechts een korte range aan logische, behulpzame waardes hebben, kan zo Optuna sneller aan goede resultaten komen.

Hierna begint de Optuna study, die dus een vooraf gespecificeerd aantal stappen gaat uitvoeren. Bij elke stap, zal een nieuw Pac-Man environment en nieuw model gecreeerd worden, en zal via PPO op deze environment voor een vooraf gespecificeerde tijd getraind worden, met de voorgestelde hyperparameters. Na deze training worden er 10 runs uitgevoerd op het getrainde model, en wordt de gemiddelde score van deze runs berekend. Dit gemiddelde benadert dan hoe goed de door Optuna voorgestelde hyperparameters waren. Hierna begint Optuna aan de volgende stap en kiest het nieuwe hyperparameters.

Als de Optuna study al zijn stappen gedaan heeft, geeft deze ons terug welke hyperparameters tot de hoogste gemiddelde score hebben geleid. Hierna voeren we dan de effectieve training uit. We trainen met PPO de agent voor een vooraf gespecificeerde tijd (die veel langer is dan de tijd van het trainen per Optuna stap), met deze beste hyperparameters. Eens deze training beeindigd is, hebben we onze getrainde agent. Deze laten we dan runs uitvoeren aan de hand van onze terminal output, zodat we met eigen ogen kunnen zien hoe goed deze agent presteert, en of hij bepaalde strategieen heeft ontdekt. We schrijven ondertussen ook de score en de overlevingstijd per run uit naar een bestand, dat we dan achteraf kunnen analyseren.

3. Resultaten

4. Conclusie

Fuck dees vak, de volgende keer doen we gewoon image recognition!